	MODELOS Y SIMULACION En la clase de hoy veremos Regresion No Lineal: Polinómica y Logarítmica. Recordaremos como valernos de ajustes lineales para tendencias no lineales. Ademas aplicaremos ANOVA para la seleccion de variables Para esta semana, siguen abiertas las Office Hours con el mismo link de siempre. Ya se encuentra disponible la solucion a la practica 2 en Google Drive. La revisaremos.
	Meet AIVA: AI Music Hoy vamos a conocer una startup que genera musica con Al. Escuchemos primero una de sus composiciones https://www.youtube.com/watch?v=wtZ-GJ3xaeU&list=PLv7BOfa4CxsHAMHQj0ScPXSbgBlLglRPo&index=66 Conozcamos un poco de su CEO and Founder: https://www.youtube.com/watch?v=wYb3Wimn01s Debatimos ¿ Es arte ? Regresion No Lineal: Polinomial
In [2]:	Veamos como mejorar nuestro R2 del modelo de Regresion Lineal de la practica 1 import pandas as pd import statsmodels.api as sm from sklearn.preprocessing import PolynomialFeatures import matplotlib.pyplot as plt import numpy as np
In [3]:	<pre>boston = pd.read_csv('boston.csv') var_explicativas = boston[['LSTAT']] var_objetivo = boston[['MEDV']] #Creamos los valores del polinomio a partir de X</pre>
	<pre>polynomial_features=PolynomialFeatures(degree=2) xp = polynomial_features.fit_transform(var_explicativas) #Devuelve X^0, X^1, X^2 print(xp) [[1.</pre>
In [5]:	<pre>[1. 6.48 41.9904] [1. 7.88 62.0944]] #Creamos y entrenamos a nuestro modelo. model = sm.OLS(var_objetivo, xp) regr = model.fit() print(regr.summary())</pre> OLS Regression Results
	Dep. Variable: MEDV R-squared: 0.641 Model: 0LS Adj. R-squared: 0.639 Method: Least Squares F-statistic: 448.5 Date: Sun, 05 Sep 2021 Prob (F-statistic): 1.56e-112 Time: 12:25:40 Log-Likelihood: -1581.3 No. Observations: 506 AIC: 3169. Df Residuals: 503 BIC: 3181. Df Model: 2 Covariance Type: nonrobust coef std err t P> t [0.025 0.975]
	const 42.8620 0.872 49.149 0.000 41.149 44.575 x1 -2.3328 0.124 -18.843 0.000 -2.576 -2.090 x2 0.0435 0.004 11.628 0.000 0.036 0.051 Omnibus: 107.006 Durbin-Watson: 0.921 Prob (Omnibus): 0.000 Jarque-Bera (JB): 228.388 Skew: 1.128 Prob (JB): 2.55e-50 Kurtosis: 5.397 Cond. No. 1.13e+03 Notes: [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
In [6]:	[2] The condition number is large, 1.13e+03. This might indicate that there are strong multicollinearity or other numerical problems. #Predizcamos los valores de precio precios = regr.predict(xp)
	plt.show() 50 40 30 20
In [12]:	10 -
	<pre>polynomial_features=PolynomialFeatures(degree=i) xp = polynomial_features.fit_transform(var_explicativas) # Entreno el modelo model = sm.OLS(var_objetivo, xp) regr = model.fit() # Grafico la dispersion de puntos plt.scatter(var_explicativas, var_objetivo) # Creo una columna con valores X para realizar la prediccion x = np.arange(N, step=0.1) x = x[:,None] xp = polynomial_features.fit_transform(x) # Obtengo los valores y a a partir de los x y = regr.predict(xp) # Grafico x vs y, para ver la grafica del polinomio plt.plot(x, y, color='red') # Añado valores plt.xlabel('NSTAT') plt.ylabel('MEDV') plt.title('Bolinomio de grado ' + str(i)) plt.text(NO, 40, 'N2 adj: ' + str(round(regr.rsquared_adj, N))) plt.show()</pre>
	Polinomio de grado 1 R2 adj: 0.543 20 10 0 5 10 15 20 25 30 35
	Polinomio de grado 2 R2 adj: 0.639 20 10 50 10 10 10 15 10 15 15 1
	Polinomio de grado 3 R2 adj: 0.656 20 10 5 10 15 20 25 30 35 LSTAT
	Polinomio de grado 4 R2 adj: 0.67 20 10 Polinomio de grado 5
	70 60 50 40 20 10 10 5 10 15 20 25 30 35
	Polinomio de grado 6 70 - 60 - 50 - 40 - 40 - 40 - 40 - 40 - 40 - 4
	Polinomio de grado 7 70 60 50 40 20 10 5 10 15 20 25 30 35
	Polinomio de grado 8 R2 adj: 0.679 20 10 5 10 15 20 25 30 35
	Polinomio de grado 9 R2 adj: 0.68 20 10 5 10 15 20 25 30 35
In [9]:	<pre># El que mejor ajusta en este caso es un polinomio de grado 3 polynomial_features=PolynomialFeatures(degree=3) xp = polynomial_features.fit_transform(var_explicativas) # Entreno el modelo model = sm.OLS(var_objetivo, xp) regr = model.fit() print(regr.summary())</pre>
	Dep. Variable: MEDV R-squared: 0.658 Model: 0L6 Adj. R-squared: 0.656 Method: Least Square F-statistic: 321.7 Date: Sun, 05 Sep 2021 Prob (F-statistic): 1.78e-116 Time: 12:25:47 Log-Likelihood: -1568.9 No. Observations: 506 AIC: 3146. Df Residuals: 502 BIC: 3163. Df Model: 3 Covariance Type: nonrobust
In [21]:	<pre>x_log = np.log10(var_explicativas) y_log = np.log10(var_objetivo) plt.scatter(x_log, y_log) plt.xlabel('Log(LSTAT)')</pre>
	plt.ylabel('Log(MEDV)') plt.show()
In [24]:	1.0 - 0.8 - 0.2 0.4 0.6 0.8 1.0 1.2 1.4 1.6 Log(LSTAT)
	regr = model.fit() print(regr.summary()) OLS Regression Results Dep. Variable: MEDV R-squared: 0.677 Model: OLS Adj. R-squared: 0.677 Method: Least Squares F-statistic: 1058. Date: Sun, 05 Sep 2021 Prob (F-statistic): 7.32e-126 Time: 12:48:27 Log-Likelihood: 443.35 No. Observations: 506 AIC: -882.7 Of Residuals: 504 BIC: -874.2 Df Model: 1 Covariance Type: nonrobust
	coef std err t P> t [0.025] 0.975] const 1.8943 0.018 103.603 0.000 1.858 1.930 LSTAT -0.5598 0.017 -32.521 0.000 -0.594 -0.526
In [33]:	Notes: [1] Standard Errors assume that the covariance matrix of the errors is correctly specified. # Grafiquemos nuestro modelo y_log_pred = regr.predict(x_log) plt.scatter(x_log['LSTAT'], y_log) plt.plot(x_log['LSTAT'], y_log_pred, 'r') plt.xlabel('Log(LSTAT)') plt.ylabel('Log(MEDV)') plt.text(1.3, 1.6, 'R2 ADJ: ' + str(round(regr.rsquared_adj,3))) plt.show()
	1.8 1.6 1.4 1.2 1.0 1.0 0.8
In [70]:	<pre>beta_0 = regr.params[0] beta_1 = regr.params[1] # Transformamos los valores a = np.power(10, beta_0) # Armamos los valores del modelo x = np.arange(start=2, stop=37, step=0.1) x = x[:,None]</pre>
In [73]:	<pre>y_model = a * np.power(x, beta_1) print(x.size, y_model.size) 350 350 # Visualicemos plt.scatter(var_explicativas, var_objetivo) plt.plot(x, y_model, 'r') plt.xlabel('LSTAT') plt.ylabel('MEDV')</pre>
	plt.ylabel('MEDV') plt.text(30, 40, 'R2 ADJ: ' + str(round(regr.rsquared_adj, 3))) plt.show() R2 ADJ: 0.677
In [84]:	ANOVA para la seleccion de variables
In [111.	<pre>boston = pd.read_csv('boston.csv') var_explicativas = boston.drop('MEDV', 1) var_explicativas = sm.add_constant(var_explicativas) var_objetivo = boston[['MEDV']] # Creemos modelos donde incorporamos variables incrementales model_1 = sm.OLS(var_objetivo, var_explicativas[['const', 'LSTAT']]).fit()</pre>
In [113.	# M2 admite mas variables, P value de comparacion M2 con M1 cercano a 0 # M3 es un modelo apropiado, P value de comparacion M3 con M2 cercano a 0,0014 # M4 ya no es un modelo apropiado, P value de comparacion M4 con M3 de 0,963
	<pre>print(table) df_resid</pre>